

# Detecção de Fraudes em Transações Bancárias com Aprendizado de Máquina

Análise e Modelagem Preditiva com foco em F1-Score

Cientista de Dados  
EBAC

Banco Global Trust  
(Fictício)



# O Custo da Confiança



## Perdas Milionárias Anuais

Fraudes financeiras representam um risco sistêmico, comprometendo o capital e a lucratividade das instituições.



## Erosão da Confiança do Cliente

A falha na proteção de ativos compromete a reputação e a lealdade, impactando a base de clientes a longo prazo.

Mesmo um desequilíbrio de **0.1% em falsos negativos** (fraudes não detectadas) pode representar milhões em prejuízo financeiro direto e indireto.



Desafio e Foco da Modelagem

## Objetivo: Equilíbrio Ótimo de Desempenho

### Modelo Preditivo Robusto

Desenvolver um modelo de Machine Learning capaz de identificar transações fraudulentas com alta acurácia e velocidade.

### Mínimo de Falsos Alertas

É crucial manter o mínimo de Falsos Positivos para não sobrecarregar as equipes de risco e evitar a má experiência do cliente.

### Métrica Principal: F1-Score

Priorizamos o F1-Score, pois ele mede o equilíbrio entre **Recall** (detecção de fraudes reais) e **Precision** (evitar falsos alarmes).

### Confiabilidade dos Dados


Garantir a qualidade e o balanceamento dos dados é essencial para reduzir vieses e aumentar a confiança nas decisões automatizadas.

## Análise Exploratória do Dataset

# Características dos Dados Financeiros

- Dataset composto por **284.807 transações financeiras anônimas**, representativas de um período operacional de dois dias em setembro de 2023.
- Variáveis de entrada transformadas via **Análise de Componentes Principais (PCA)**: V1 a V28, protegendo dados sensíveis.
- A classe alvo (fraude) é **extremamente minoritária**, caracterizando um problema de dados desbalanceados.

Este desbalanceamento (**0.17%** de fraudes) é o maior desafio, exigindo técnicas avançadas de preparação de dados para garantir que o modelo não ignore a classe minoritária.





## Estratégias de Balanceamento

# Preparação para Superar o Desafio do Desequilíbrio

Para garantir que o modelo aprenda de forma eficaz o padrão sutil das transações fraudulentas, aplicamos a técnica **SMOTE (Synthetic Minority Oversampling Technique)**.

### Antes do SMOTE



Desbalanceamento severo: Fraudes representam menos de 0.2% do dataset, dificultando o aprendizado.

### Mecanismo de Geração



Geramos exemplos sintéticos da classe minoritária (fraude) em sua vizinhança, preservando suas características estatísticas.

### Após o Balanceamento



O modelo recebe uma representação mais equilibrada das classes, melhorando a capacidade de generalização e detecção.

## Metodologia Técnica

# Experimentação e Otimização de Modelos

Utilizamos uma abordagem comparativa com validação cruzada para avaliar o desempenho de algoritmos consagrados na detecção de anomalias.



### Regressão Logística

Modelo base linear, oferece alta interpretabilidade e velocidade de treinamento.



### Random Forest

Conjunto de árvores de decisão, eficaz contra overfitting e ruído nos dados.



### XGBoost (Gradient Boosting)

Algoritmo de ponta, conhecido por sua alta performance em desafios de classificação complexos.

📌 A otimização de hiperparâmetros foi realizada via **RandomizedSearchCV**, garantindo a maximização do F1-Score sem comprometer o tempo de processamento.

## Resultados Consolidados

# XGBoost: O Modelo Vencedor

O modelo XGBoost foi o escolhido. Ele funciona como uma **balança de precisão** que, ao ser **ajustada**, nos permite maximizar o acerto nas fraudes (Recall) ao mesmo tempo que reduz o número de alarmes falsos, garantindo o melhor resultado financeiro para o banco.

0.87

F1-Score

Indica o equilíbrio superior na detecção de fraudes e na minimização de falsos positivos.

0.98

ROC AUC

Área sob a curva robusta, demonstrando a excelente capacidade de discriminação do modelo.

0.96

Precision

Dos alertas emitidos, 96% correspondem a fraudes reais (baixo Falso Positivo).

Valor de Negócio e Impacto Estratégico

# Traduzindo Métricas em Ganhos Operacionais

## Redução de Perdas Diretas

Detecção precoce e precisa de fraudes minimiza o desembolso financeiro do banco.



## Eficiência Operacional

A baixa taxa de Falsos Positivos otimiza o tempo da equipe de risco, focando recursos em casos reais.



## Integração em Tempo Real

O modelo é leve e pode ser integrado à API de transações para decisões instantâneas (milissegundos).



## Experiência do Cliente

Diminuição de bloqueios indevidos em transações legítimas, elevando a satisfação e confiança.





# Sumário Executivo e Fechamento

## 1 Problema de Alto Impacto Resolvido

O desafio do desbalanceamento extremo foi superado, transformando um problema de risco em uma oportunidade de otimização.

## 2 Solução Robusta e Estatisticamente Validada

Com XGBoost otimizado, alcançamos um F1-Score de 0.87, validando a eficácia e o equilíbrio entre Recall e Precision.

## 3 Geração de Valor Imediato

O modelo está pronto para ser implementado, reduzindo perdas diretas e aumentando a satisfação do cliente.

# Menos Perdas. Mais Confiança.

# Obrigado!

Este projeto de Detecção de Fraude foi desenvolvido como Trabalho de Conclusão para o curso de **Cientista de Dados da EBAC**.

**Leonardo Prado**